

Proste wykrywanie dryfu testem t-Studenta

Cel

Celem zadania jest sprawdzenie, czy dwa zbiory danych różnią się na tyle, aby uznać, że nastąpiła zmiana (dryf).

Dane

Mamy dwa zbiory:

- X_1 — dane referencyjne (wcześniejsze)
- X_2 — dane aktualne (nowe)

Hipotezy statystyczne

$H_0 : \mu_1 = \mu_2$ (*brak_dryfu*)

$H_1 : \mu_1 \neq \mu_2$ (*dryfu*)

Średnia

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i \quad (1)$$

Wariancja (próbkowa)

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2 \quad (2)$$

Statystyka testowa

$$T = \frac{|\mu_1 - \mu_2|}{\sqrt{\frac{s_1^2 + s_2^2}{2}}} \quad (3)$$

gdzie:

- μ_1, μ_2 — średnie
- s_1^2, s_2^2 — wariancje

Stopnie swobody

$$df = n_1 + n_2 - 2 \quad (4)$$

Próg decyzyjny

$$t_{crit} = t_{1-\frac{\alpha}{2}, df} \quad (5)$$

gdzie:

- α — poziom istotności (np. 0.05)

Reguła decyzyjna

$$\begin{aligned} T &> t_{crit} \Rightarrow dryf \\ T &\leq t_{crit} \Rightarrow brak_dryfu \end{aligned}$$

Interpretacja

- Duża wartość T oznacza dużą różnicę między zbiorami
- Test działa bez etykiet (unsupervised)
- Metoda jest wrażliwa na zmianę średniej

Uwaga dydaktyczna

Jest to uproszczona wersja testu t-Studenta — używana do nauki idei wykrywania drifu.

Klasyczny test t-Studenta (pełna wersja)

W pełnym teście t-Studenta statystyka testowa ma postać:

$$t = \frac{|\mu_1 - \mu_2|}{\sqrt{s_p^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \quad (6)$$

gdzie wariancja połączona (pooled variance) wynosi:

$$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2} \quad (7)$$

Stopnie swobody:

$$df = n_1 + n_2 - 2 \quad (8)$$

Próg decyzyjny:

$$t_{crit} = t_{1-\frac{\alpha}{2}, df} \quad (9)$$

Reguła decyzyjna:

$$\begin{aligned} |t| &> t_{crit} \Rightarrow dryf \\ |t| &\leq t_{crit} \Rightarrow brak_dryfu \end{aligned}$$

Różnica względem wersji uproszczonej

Wersja uproszczona:

- nie uwzględnia liczności próbek n_1, n_2 ,
- używa średniej wariancji zamiast wariancji połączonej,
- pełni rolę intuicyjnej miary różnicy.

Klasyczny test t-Studenta:

- uwzględnia licznosc danych,
- poprawnie estymuje wariancje,
- pozwala kontrolować błąd statystyczny,
- jest standardem w analizie danych.